지정학적 리스크를 반영한
원자재 이상 변동 감지 및 가격 예측

제출 2 - 모델 확장 & 비교

머신러닝 학기 프로젝트

조장 : 20232501 임태후　조원 : 20232514 유종헌

1. 모델 선택 이유

1.1 1주차 한계와 개선 방향

1주차에서는 Random Forest 단일 모델로 이상 변동 감지를 시도했으나, 다음과 같은 한계가 확인되었다.

한계점	상세 설명	2주차 대응
시간 순서 무시	데이터를 무작위로 섞어 나누었기 때문에 미래 데이터가 학습에 포함되는 데이터 누출(data leakage)이 발생하였다. 이로 인해 1주차 성능(F1: 0.393)은 현실에서 재현 불가능한 부풀려진 수치였다.	TimeSeriesSplit 5-Fold로 항상 과거→미래 순서 보장
단일 모델	Random Forest만 사용하여 해당 모델이 최적인지 판단할 근거가 없었다. 데이터 특성에 따라 다른 알고리즘이 더 좋은 성능을 보일 수 있다.	5개 모델(RF, LR, SVM, XGBoost, KNN) 비교 분석
Recall 부족	Recall 28.3%로 실제 이상변동 100건 중 72건을 놓쳤다. 데이터 불균형(정상 64.5% vs 이상 35.5%)으로 모델이 '정상'에 편향되었다.	다양한 모델로 Recall 개선 시도

1.2 선택한 5개 모델과 선택 이유

모델	유형	선택 이유
Random Forest	앙상블 (Bagging)	1주차 기준 모델. TimeSeriesSplit 적용 시 성능 변화를 확인하기 위해 재실행
Logistic Regression	선형 분류	가장 단순한 분류 모델로서 성능 하한선(baseline)을 설정. 해석이 쉬워 변수별 영향도 분석에 유리
SVM	커널 기반 분류	RBF 커널로 비선형 경계를 학습 가능. 고차원 데이터에서 효과적이며, 소규모 데이터에 강점
XGBoost	앙상블 (Boosting)	Gradient Boosting 기반으로 일반적으로 분류 성능이 가장 높음. 불균형 데이터 처리에 강점
KNN	거리 기반 분류	학습 없이 유사 패턴을 직접 비교. 데이터 분포에 의존하므로 시계열 특성이 반영되는지 확인

1.3 사용 도구: scikit-learn & XGBoost

scikit-learn(sklearn)은 Python 환경에서 머신러닝 모델의 학습, 예측, 평가를 간편하게 수행할 수 있도록 제공되는 라이브러리이다. 본 프로젝트에서는 다음과 같은 기능을 활용하였다.

- 분류 모델: Random Forest, Logistic Regression, SVM, KNN, XGBoost
- 전처리: StandardScaler를 이용한 데이터 정규화
- 평가 지표: Accuracy, Precision, Recall, F1-Score, ROC-AUC
- 교차검증: TimeSeriesSplit (시계열 전용 교차검증)

1.4 평가 방법: TimeSeriesSplit

TimeSeriesSplit은 시계열 데이터 전용 교차검증 방법으로, 항상 과거 데이터로 학습하고 미래 데이터로 테스트한다. Fold가 진행될수록 학습 데이터가 점점 늘어나며, 미래 데이터가 학습에 절대 포함되지 않으므로 데이터 누출(data leakage)을 방지할 수 있다. 이를 통해 실제 투자 환경과 동일한 조건에서 모델을 평가하였다.

Fold	학습 기간 (일)	테스트 기간 (일)	설명
Fold 1	262	259	최소 학습량으로 예측 (가장 어려운 조건)
Fold 2	521	259	약 2년치 학습
Fold 3	780	259	약 3년치 학습
Fold 4	1,039	259	약 4년치 학습
Fold 5	1,298	259	최대 학습량 (가장 유리한 조건)

Fold를 1→5로 점진적으로 확장하는 이유:

TimeSeriesSplit은 Fold가 진행될수록 학습 데이터가 점점 늘어나는 구조이다. 이를 통해 단순히 모델의 평균 성능만 측정하는 것이 아니라, 학습 데이터가 많아질수록 모델의 성능이 개선되는지, 그리고 특정 시기(예: 전쟁, 위기)의 데이터가 포함되었을 때 성능이 어떻게 변하는지를 추적할 수 있다. 즉, 모델의 안정성(stability)과 데이터 양에 따른 학습 효과를 동시에 검증하는 것이 핵심 목적이다.

또한 SVM, KNN, Logistic Regression 등 스케일에 민감한 모델을 위해 StandardScaler를 적용하였다. 학습 데이터를 기준으로 정규화한 뒤, 같은 기준을 테스트 데이터에도 적용하여 데이터 누출을 방지하였다.

2. 성능 비교

2.1 모델별 평균 성능 (5-Fold)

모델	Accuracy	Precision	Recall	F1-Score
Random Forest	0.635	0.379	0.245	0.289
Logistic Regression	0.676	0.435	0.144	0.205
SVM	0.665	0.461	0.187	0.258
XGBoost	0.632	0.406	0.286	0.324
KNN	0.602	0.372	0.285	0.317

→ F1-Score 기준 XGBoost가 0.324로 최고 성능. Recall 기준으로도 XGBoost가 0.286으로 1위.

2.2 모델별 성능 비교 차트

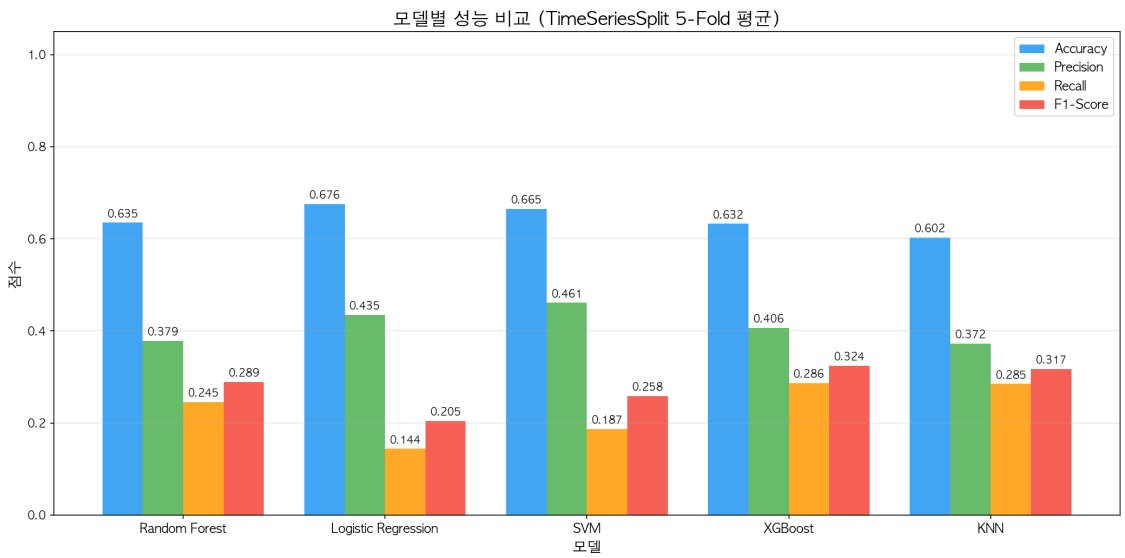

2.3 ROC 커브 비교

ROC 커브는 임계값(threshold)을 변화시키면서 True Positive Rate와 False Positive Rate의 관계를 보여준다. AUC가 1에 가까울수록 좋은 모델이다.

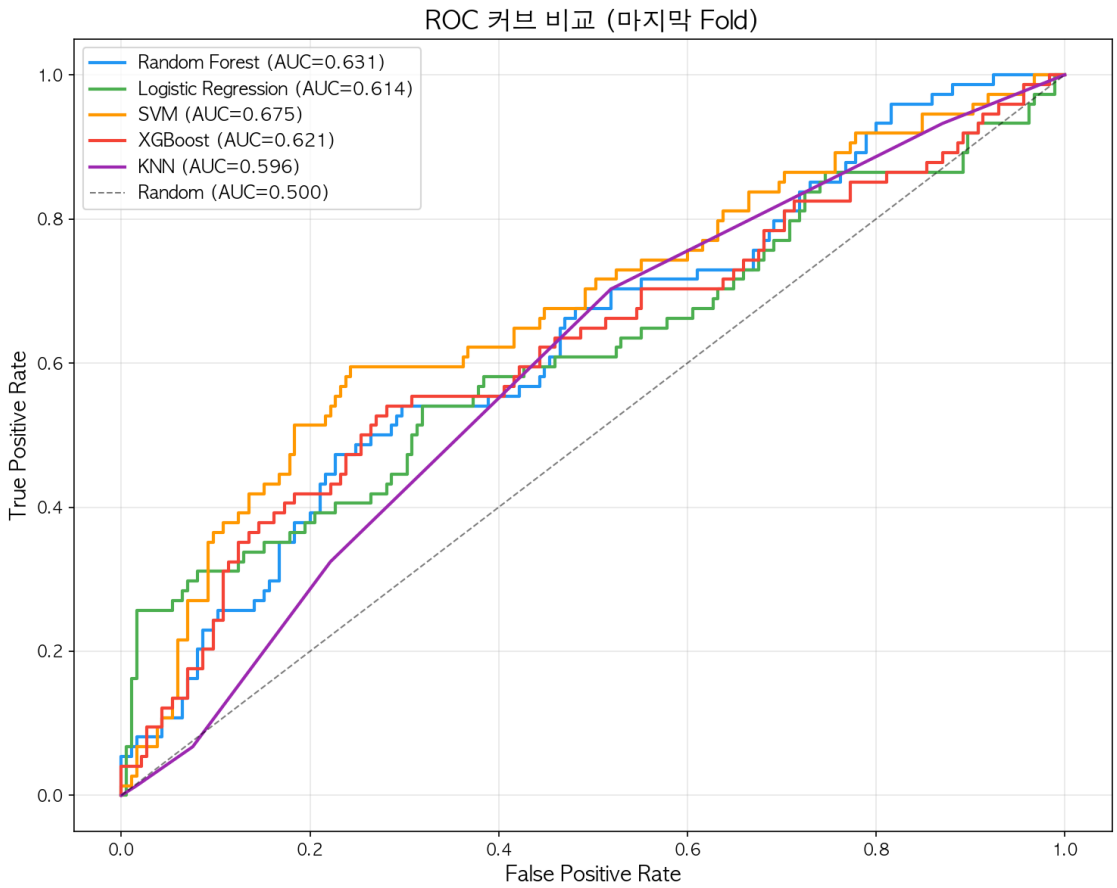

모델	AUC	해석
SVM	0.675	확률 기반 판단에서 가장 우수
Random Forest	0.631	앙상블 효과로 안정적
XGBoost	0.621	F1은 최고지만 AUC는 중간
Logistic Regression	0.614	단순 모델 대비 준수
KNN	0.596	가장 낮은 AUC

2.4 혼동 행렬 비교 (마지막 Fold)

각 모델의 혼동 행렬을 통해 정상/이상변동 분류 결과를 시각적으로 확인한다. 이상변동 감지가 목적이므로 각 칸의 의미는 다음과 같다: 좌상단(TN)은 정상을 정상으로 분류한 것으로 맞는 예측이지만, 이 값이 크다고 좋은 것이 아니라 모델이 '정상'만 예측하는 편향의 신호일 수 있다. 우하단(TP)은 이상변동을 이상으로 감지한 것으로 이 값이 클수록 좋으며 Recall과 직결된다. 좌하단(FN)은 실제 이상변동을 정상으로 놓친 것으로 가장 치명적인 오류이다. 우상단(FP)은 정상을 이상으로 오판한 허위 경보이다.

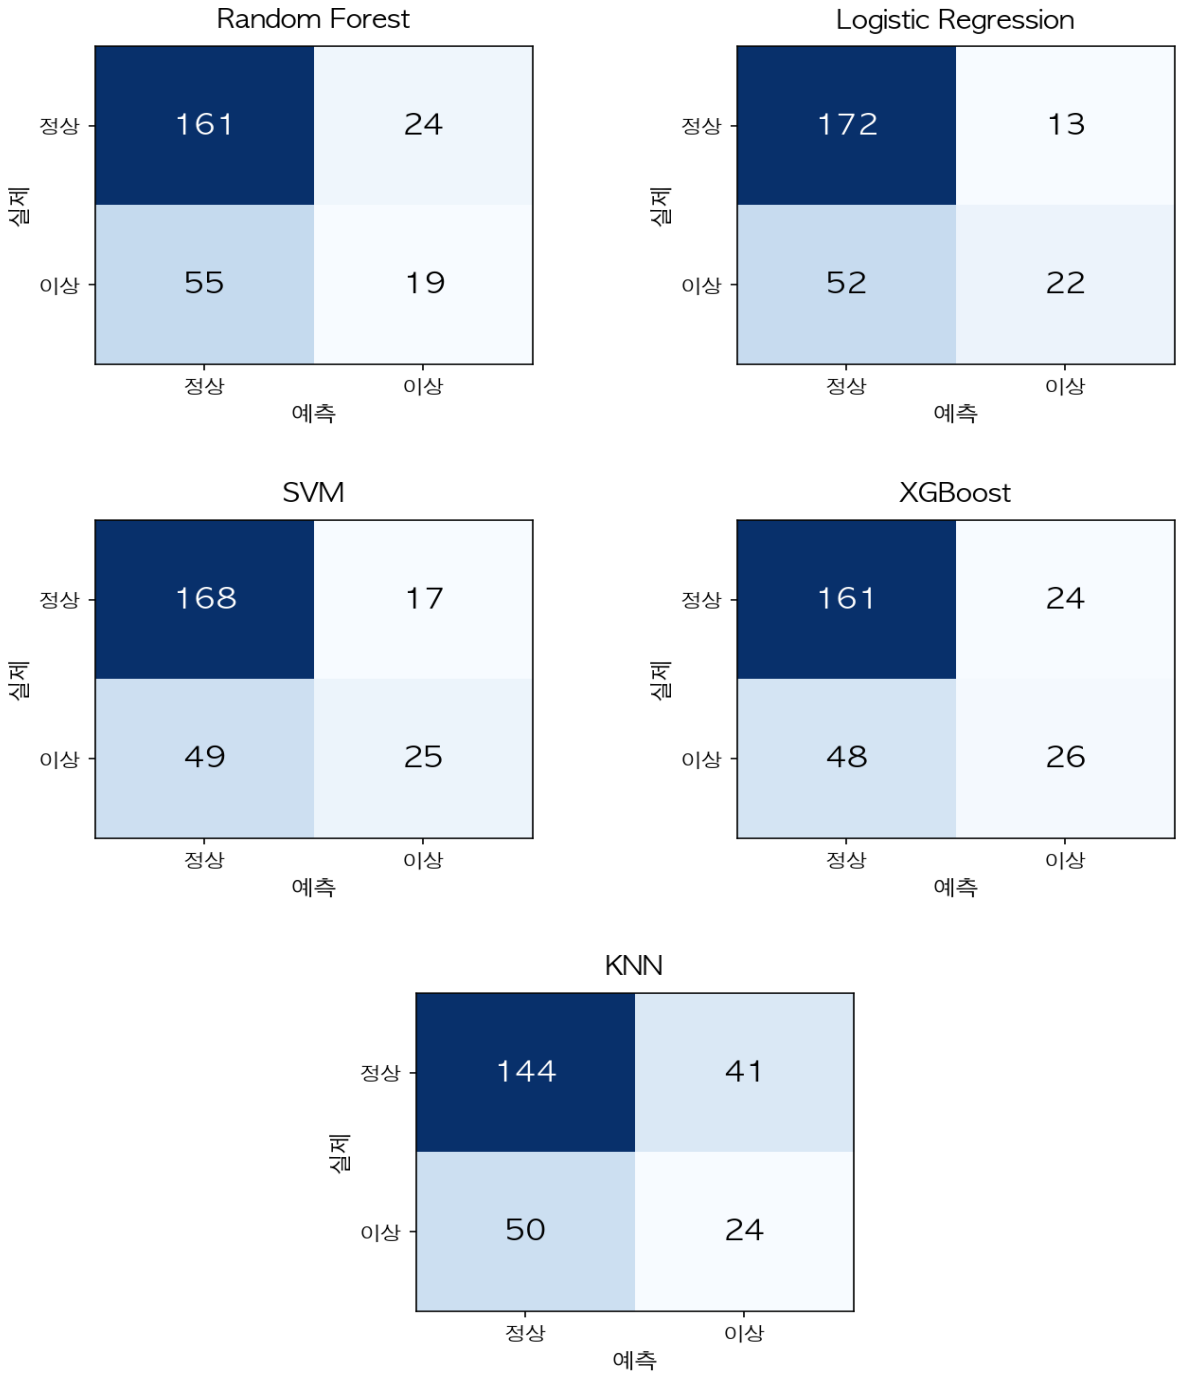

→ XGBoost가 이상변동(우하단) 26건으로 가장 많이 감지하였으며, SVM이 25건으로 2위를 기록하였다.

2.5 Fold별 F1-Score 변화 (모델 안정성)

Fold가 진행될수록 학습 데이터가 많아진다. 안정적인 모델은 Fold 간 성능 변동이 작아야 한다.

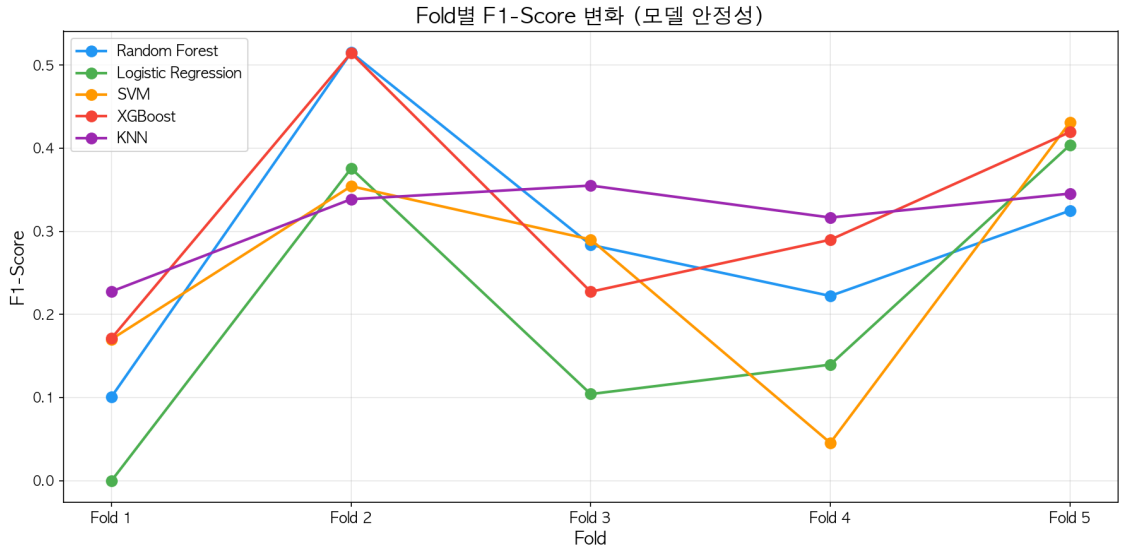

→ 모든 모델이 Fold 2에서 급등 후 Fold 3~4에서 하락하는 패턴을 보인다. 이는 2021~2022년 러시아-우크라이나 전쟁 기간의 높은 변동성이 학습에 포함되면서 이후 안정기 예측이 어려워지는 현상으로 해석된다.

2.6 1주차 vs 2주차 비교 (Random Forest 기준)

지표	1주차 (Random Split)	2주차 (TimeSeriesSplit)	변화
Accuracy	0.683	0.635	↓ 0.048
Precision	0.640	0.379	↓ 0.261
Recall	0.283	0.245	↓ 0.038
F1-Score	0.393	0.289	↓ 0.103

→ 모든 지표가 하락하였다. 이는 TimeSeriesSplit이 더 현실적인 평가 방법이기 때문이며, 1주차의 높은 성능은 Random Split으로 인한 미래 데이터 누출(data leakage)로 부풀려진 결과였음을 의미한다.

2.7 회귀(수익률 예측) 성능 비교

분류(이상변동 감지) 외에, 각 모델의 회귀 버전을 사용하여 원유 수익률 예측 성능도 비교하였다. XGBRegressor, RandomForestRegressor, SVR, KNeighborsRegressor, LinearRegression을 동일한 TimeSeriesSplit 5-Fold 조건에서 평가하였다.

모델	MAE	RMSE	R^2	해석
SVM (SVR)	1.770	2.354	-0.029	회귀 성능 1위. R^2가 0에 가장 가까움
KNN	1.962	2.558	-0.222	MAE 기준 2위
XGBoost	1.956	2.648	-0.303	분류 1위이나 회귀는 3위
Random Forest	2.067	3.424	-1.239	회귀에서 가장 불안정
Linear Regression	2.376	3.100	-0.796	선형 모델의 한계

→ 회귀 성능은 SVR이 1위이나, 모든 모델의 R^2가 음수로 현재 Feature만으로는 수익률 예측이 충분하지 않다.

회귀 성능의 한계와 XGBoost 선정 이유:

- R^2가 모두 음수 → 단순 평균값 예측보다 못하며, 시차 Feature와 기술 지표 추가가 필요
- SVR이 회귀 1위이나, 학습 속도가 느리고 대규모 데이터에 불리하며 분류 성능(Recall)은 XGBoost보다 낮음
- XGBoost는 분류(F1, Recall 1위) + 회귀(3위)를 하나의 프레임워크에서 모두 처리 가능하고, scale_pos_weight로 클래스 불균형 처리까지 내장되어 있어 종합적으로 최적

3. 결과 해석

3.1 최적 모델: XGBoost

F1-Score(0.324)와 Recall(0.286) 모두에서 XGBoost가 최고 성능을 기록하였다. 이상 변동 감지라는 목적상, 이상변동을 놓치지 않는 것(Recall)이 가장 중요한 지표이므로 XGBoost가 현재 데이터에 가장 적합한 모델이다.

XGBoost가 3가지 과제 모두에 강한 이유:

① 이상변동 감지 (Classification: 이상 vs 정상)

- 클래스 불균형 처리: scale_pos_weight 파라미터를 통해 소수 클래스(이상변동)를 틀렸을 때 벌점을 더 크게 부여할 수 있어, 모델이 이상변동을 더 적극적으로 찾게 됨
- 부스팅 방식: 이전 트리가 놓친 이상변동 샘플에 집중하여 다음 트리를 생성하므로, 1주차 핵심 약점이었던 Recall(28.3%) 개선에 유리

② 가격 방향 예측 (Classification: 상승 vs 하락)

- 비선형 패턴 학습: VIX 급등 + GPR 상승 시 하락, 같은 복합 조건을 트리 구조로 자연스럽게 포착
- 순차 보정(Gradient Boosting): Random Forest가 여러 트리를 독립적으로 만들어 평균내는 방식이라면, XGBoost는 이전 트리의 오류를 교정하면서 학습하여 방향 예측 정확도 향상에 유리

③ 수익률 예측 (Regression: 몇 % 변동)

- XGBRegressor로 회귀 분석도 가능하여, 동일한 프레임워크에서 분류와 회귀를 모두 처리
- 정규화(L1/L2) 내장: Random Forest에 없는 과적합 방지 기능이 있어 노이즈가 많은 수익률 데이터에서도 안정적 예측 가능

공통 강점:

- 학습률(Learning Rate) 조절로 세밀한 튜닝이 가능하다 (Random Forest에는 없는 기능)
- 조기 종료(Early Stopping) 기능으로 모델이 과적합되기 전에 자동으로 학습을 중단할 수 있다
- 변수 중요도(Feature Importance)를 통해 3가지 과제에서 어떤 변수가 중요한지 일관되게 비교할 수 있다

3.2 모델별 특성 분석

모델	강점	약점	종합 평가
XGBoost	F1, Recall 최고. 불균형 데이터에 강함	Accuracy는 RF보다 낮음	★ 이상변동 감지에 가장 적합
KNN	Recall 2위(0.285). 구현이 단순	Accuracy 최하위. 안정성 부족	보조 모델로 활용 가능
Random Forest	Fold 간 성능이 비교적 안정적	Recall이 낮아 이상변동 놓침	안정성은 좋으나 감지력 부족
SVM	AUC 최고(0.675). Precision 1위	Recall 낮음. 학습 속도 느림	확률 기반 경보에 활용 가능
Logistic Regression	Accuracy 최고(0.676). 해석 용이	Recall 최하위(0.144)	이상변동 감지에는 부적합

3.3 왜 모든 모델의 성능이 낮은가?

5개 모델 모두 F1-Score가 0.2~0.3 수준으로, 이상변동 감지 성능이 충분하지 않다. 이는 모델의 문제가 아니라 현재 Feature의 한계로 판단된다.

- 당일 GPR/VIX 값만 사용, 시차(Lag) Feature 부재
- 이동평균, 볼린저밴드 등 기술적 지표 미포함
- 이상변동 기준이 ±2% 고정, 변동성 적응형 기준 필요

3.4 다음 단계 개선 계획

개선 항목	구체적 방법	기대 효과
시차 Feature 추가	전일/전주 GPR, VIX 변화량을 Feature로 추가	지연된 시장 반응 포착
기술적 지표 추가	이동평균(MA), 볼린저밴드, RSI 등	가격 추세 정보 반영
하이퍼파라미터 튜닝	GridSearch / RandomSearch로 최적 파라미터 탐색	모델 성능 극대화
클래스 불균형 처리	SMOTE, class_weight 조정	Recall 개선

부록: 사용 도구 및 환경

항목	내용
프로그래밍 언어	Python 3.9
실행 환경	Google Colab
데이터	1주차 통합 데이터 (commodity_vix_gpr_data.xlsx, 1,558일)
머신러닝	scikit-learn (RF, LR, SVM, KNN), XGBoost
교차검증	TimeSeriesSplit (5-Fold)
전처리	StandardScaler
시각화	matplotlib